MINERÍA DE DATOS Y MODELIZACIÓN PREDICTIVA

'ACP y Clustering'

Pedro Pablo Vicente González, 48751969 L

Entrega: 12/06/2025

ÍNDICE

INTRODUCCIÓN 3

DISCUSIÓN DE DATOS 3

CORRECCIÓN DE DATOS 4

1-MATRIZ DE CORRELACIONES. 6

2-ANÁLISIS DE COMPONENTES PRINCIPALES (PCA): 8
Selección de componentes principales.

3-ANÁLISIS DE COMPONENTES PRINCIPALES (PCA): 9
Análisis con 2 componentes principales.

4-AGRUPAMIENTO JERÁRQUICO. 14

5-AGRUPAMIENTO K-MEDIAS. 16

6-VALIDACIÓN DEL AGRUPAMIENTO. 17

7-MÉTODO JERÁRQUICO VS K-MEDIAS. 19
Comparativa entre análisis.

8-INTERPRETACIÓN DE LOS GRUPOS. 20

9-RESUMEN DE HALLAZGOS Y CONCLUSIÓN. 21

INTRODUCCIÓN

En este informe se presenta un análisis exploratorio del dataset “palmerpenguins”, un conjunto de datos recabado por la Doctora Kristen Gorman que relata algunas de las características de tres especies de pingüinos: Adelie, Chinstrap y Gentoo. El set de datos puede ser dividido en dos tipos de características, las físicas (discretas, relativas a mediciones sobre su cuerpo) y las categóricas (relativas al género, especie y recopilación de los datos). Estas son:

- ***species***: Es la especie de pingüino. Hay tres especies en el conjunto de datos: *Adelie*, *Chinstrap* y *Gentoo*.
- ***island***: Representa la isla donde se recopilaron los datos. Las islas son *Biscoe*, *Dream* y *Torgersen*.
- ***bill_length_mm***: Longitud del pico en milímetros.
- ***bill_depth_mm***: Profundidad del pico en milímetros.
- ***flipper_length_mm***: Longitud de la aleta en milímetros.
- ***body_mass_g***: Masa corporal del pingüino en gramos.
- ***sex***: Género del pingüino, con las categorías *Male* (macho), *Female* (hembra) o *NaN* (si no está disponible).

A lo largo del estudio discutiremos el uso de diferentes técnicas utilizadas para estudiar la agrupación de dichas especies en base a sus distintas características, como lo son el Análisis de Componentes Principales o la agrupación mediante K-medias. Veremos cómo se aplican, cómo se interpretan y descubriremos las distintas perspectivas que nos puede ofrecer este tipo de análisis.

Previamente, vamos a realizar un pequeño repaso a los datos con los que estamos trabajando para poder llevar a cabo el análisis de forma correcta.

DISCUSIÓN DE DATOS

El primer paso es cargar el conjunto de datos, para ello utilizamos el método load_dataset() de la librería seaborn:

Con el dataset cargado, podemos hacer cuenta de las 7 variables de las que veníamos hablando y de que se trata de un conjunto con 344 muestras. Acaso más importante es que, podemos observar que algunas de las muestras contienen valores nulos (NaN), la tercera muestra incluso presenta como nulos cinco de sus siete valores.

```
df = sns.load_dataset("penguins")
print(df.shape)
df.head()
```

✓ 0.0s

```
(344, 7)
```

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	sex
0	Adelie	Torgersen	39.1	18.7	181.0	3750.0	Male
1	Adelie	Torgersen	39.5	17.4	186.0	3800.0	Female
2	Adelie	Torgersen	40.3	18.0	195.0	3250.0	Female
3	Adelie	Torgersen	NaN	NaN	NaN	NaN	NaN
4	Adelie	Torgersen	36.7	19.3	193.0	3450.0	Female

Otra comprobación que nos interesa hacer es que los datos estén expresados mediante una tipología correcta:

```
df.dtypes
✓ 0.0s

species              object
island               object
bill_length_mm      float64
bill_depth_mm       float64
flipper_length_mm   float64
body_mass_g         float64
sex                  object
dtype: object
```

Siendo así el caso, pasamos a la corrección de los datos.

CORRECCIÓN DE DATOS

De cara a, posteriormente, realizar el análisis de componentes principales, es fundamental que nuestros datos presenten escalas correctas y no tengan ni datos nulos ni atípicos (también es preferible que los datos estén estandarizados por temas de interpretación).

Como vamos a ver, el único problema del que debemos hacernos cargo es de tratar con los valores nulos, veremos de qué forma se estructuran a lo largo del dataset:

```
# Análisis de valores perdidos

df.isna().sum()
✓ 0.0s

species              0
island               0
bill_length_mm       2
bill_depth_mm        2
flipper_length_mm    2
body_mass_g          2
sex                 11
dtype: int64
```

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	sex
3	Adelie	Torgersen	NaN	NaN	NaN	NaN	NaN
339	Gentoo	Biscoe	NaN	NaN	NaN	NaN	NaN
324	Gentoo	Biscoe	47.3	13.8	216.0	4725.0	NaN
8	Adelie	Torgersen	34.1	18.1	193.0	3475.0	NaN
286	Gentoo	Biscoe	46.2	14.4	214.0	4650.0	NaN
336	Gentoo	Biscoe	44.5	15.7	217.0	4875.0	NaN
11	Adelie	Torgersen	37.8	17.3	180.0	3700.0	NaN
10	Adelie	Torgersen	37.8	17.1	186.0	3300.0	NaN
9	Adelie	Torgersen	42.0	20.2	190.0	4250.0	NaN
47	Adelie	Dream	37.5	18.9	179.0	2975.0	NaN

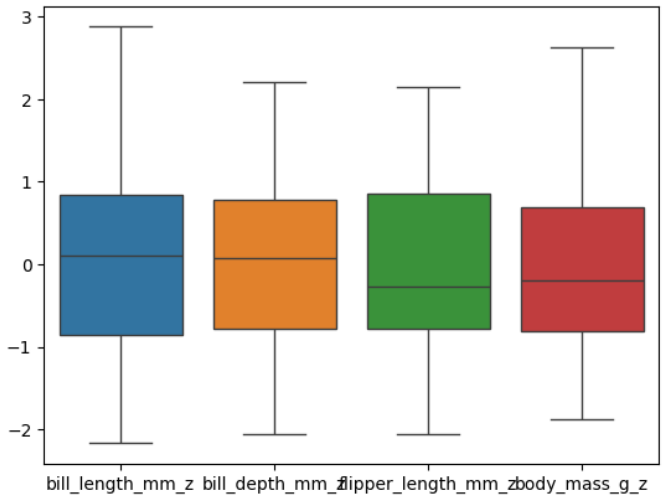
No hay muchos y, para las variables continuas, se encuentran concentrados entorno a dos muestras. Puesto que tenemos un dataset medianamente grande, la forma en que vamos a tratar con los valores nulos es eliminando las dos muestras de las que hablamos e imputando los valores restantes para la variable ‘sex’ por el valor modal (‘Male’). De cara a computar el análisis de componentes principales esta variable no será necesaria, pero posteriormente podría ser de utilidad para detectar patrones.

```
Valores nulos restantes: species           0
island             0
bill_length_mm     0
bill_depth_mm      0
flipper_length_mm  0
body_mass_g        0
sex                0
dtype: int64
```

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	sex
0	Adelie	Torgersen	39.1	18.7	181.0	3750.0	Male
226	Gentoo	Biscoe	45.4	14.6	211.0	4800.0	Female
234	Gentoo	Biscoe	45.8	14.6	210.0	4200.0	Female
233	Gentoo	Biscoe	48.4	14.6	213.0	5850.0	Male
232	Gentoo	Biscoe	45.5	13.7	214.0	4650.0	Female
231	Gentoo	Biscoe	49.0	16.1	216.0	5550.0	Male
230	Gentoo	Biscoe	40.9	13.7	214.0	4650.0	Female
229	Gentoo	Biscoe	46.8	15.4	215.0	5150.0	Male
228	Gentoo	Biscoe	43.3	13.4	209.0	4400.0	Female
227	Gentoo	Biscoe	46.7	15.3	219.0	5200.0	Male

Ahora que no hay valores nulos, vamos a estudiar la escala y los valores atípicos. La escala de las variables no será un problema tras la estandarización, las variables de distancia están medidas en milímetros y el peso en gramos. Además, estandarizar nos facilitará la visualización de los gráficos de cajas y bigotes para analizar atípicos y las distribuciones de las variables.

Tras haber estandarizado los datos de nuestras variables continuas (mediante el método StandardScaler()), los representamos mediante un gráfico de cajas y bigotes.



Podemos ver que no existen valores atípicos a lo largo de ninguna de las distribuciones. Para visualizar los datos de las variables categóricas vemos sus frecuencias:

```
species
Adelie       151
Gentoo       123
Chinstrap     68
```

```
island
Biscoe       167
Dream        124
Torgersen     51
```

```
sex
Male      177
Female    165
```

```
df_cate.value_counts()
✓ 0.0s
species    island     sex
Gentoo     Biscoe     Male      65
                      Female    58
Chinstrap  Dream      Female    34
                      Male      34
Adelie     Dream      Male      29
                      Female    27
           Torgersen  Male      27
                      Female    24
           Biscoe     Female    22
                      Male      22
```

Podemos ver como las clases modales son Adelie (especie), Biscoe (isla) y Macho (género). Por otra parte, el tipo de pingüino más común es el Macho Gentoo de la isla de Biscoe (la única en la que fueron tomados datos de eta especie).

Para finalizar el preanálisis de nuestro dataset vamos a dar un repaso a los estadísticos descriptivos para nuestras variables continuas:

```
v_cont = list(df_cont.columns)

describe_t = pd.DataFrame(df.describe()).T

estadisticos = describe_t.join(pd.DataFrame({
    'Varianza': df[v_cont].var(),
    'Coeficiente de Variación': (df[v_cont].std() / df[v_cont].mean())
}))

display(estadisticos)
```

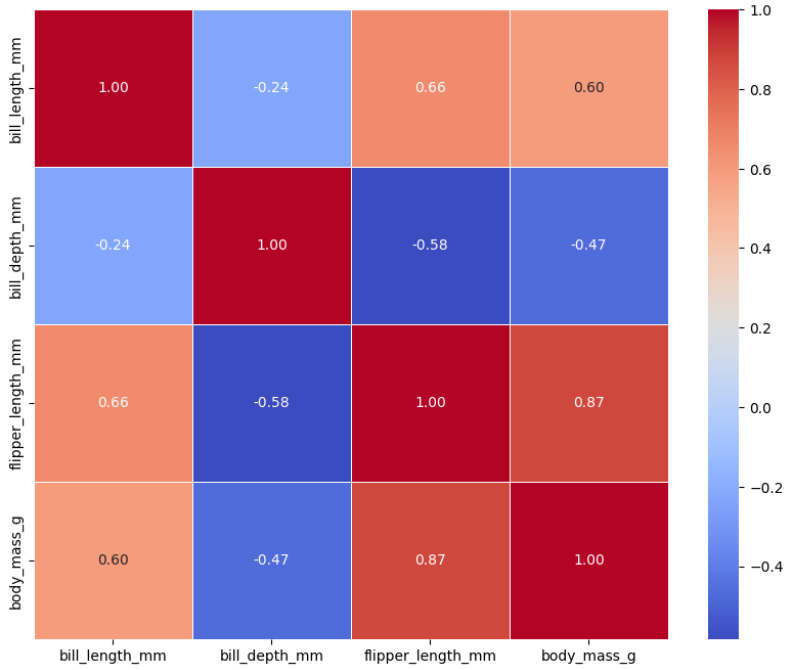
✓ 0.0s

	count	mean	std	min	25%	50%	75%	max	Varianza	Coeficiente de Variación
bill_length_mm	342.0	43.921930	5.459584	32.1	39.225	44.45	48.5	59.6	29.807054	0.124302
bill_depth_mm	342.0	17.151170	1.974793	13.1	15.600	17.30	18.7	21.5	3.899808	0.115140
flipper_length_mm	342.0	200.915205	14.061714	172.0	190.000	197.00	213.0	231.0	197.731792	0.069988
body_mass_g	342.0	4201.754386	801.954536	2700.0	3550.000	4050.00	4750.0	6300.0	643131.077327	0.190862

Podemos comprobar datos como la media, los cuartiles de la distribución y la varianza, pero el dato más interesante es el coeficiente de variación. Este estadístico es adimensional por lo que la escala no afecta a la interpretación, lo que podemos sacar en claro es que "peso" es la variable con mayor variabilidad respecto de la media y "longitud del ala" es la que menor variabilidad presenta. Continuamos nuestro análisis estudiando la relación entre variables.

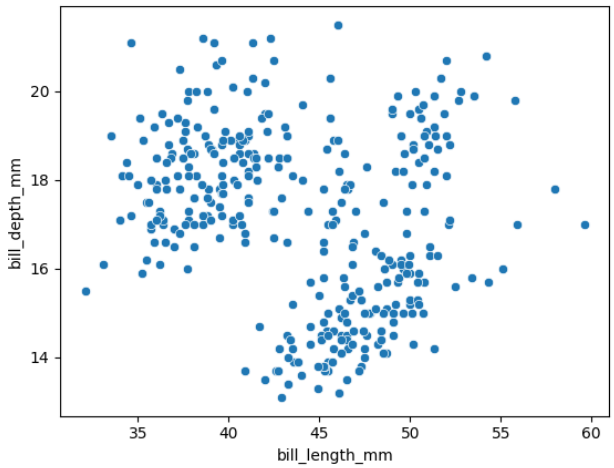
1. MATRIZ DE CORRELACIONES.

Para estudiar las relaciones entre las distintas variables vamos a calcular la matriz de correlaciones:

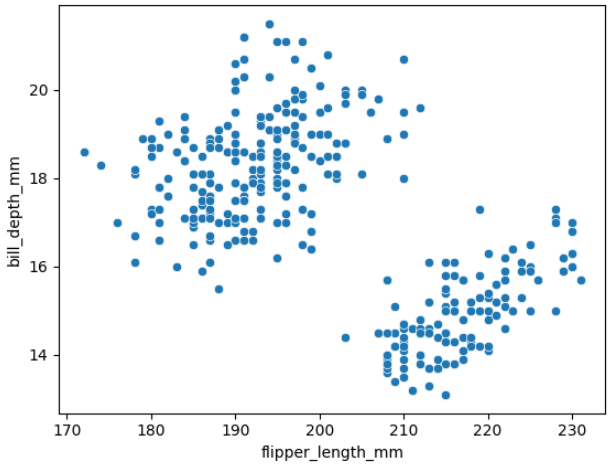


Los resultados que obtenemos nos permiten establecer una serie de primeros patrones que pueden servir como hipótesis a contrastar con el resto de análisis:

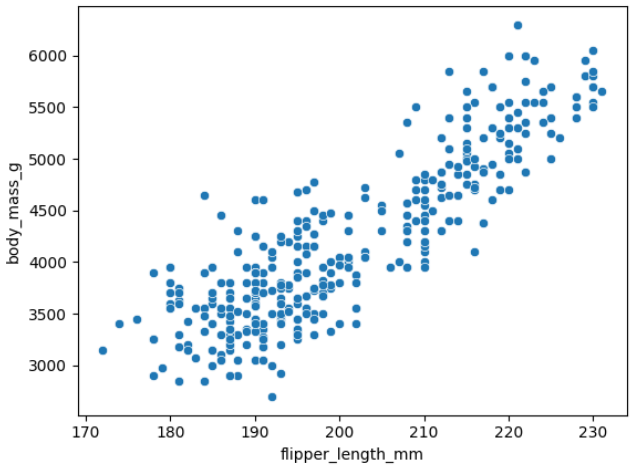
- La alta correlación entre "body_mass_g" y "flipper_lenght_mm" nos permite considerar que cuanto más pese un pingüino, más largas esperamos que sean sus alas.
- La correlación entre la longitud y la altura (profundidad del perfil de pico) de los pingüinos es negativa, aunque no esté especialmente marcada.
- También, si nos fijamos en las correlaciones con "body_mass_g", podemos distinguir dos tipos de pingüino: aquellos más pesados, con un pico más largo y menos alto (baja profundidad del perfil de pico); y aquellos poco pesados, con un perfil de pico menos alargado y más alto.
- A su vez, los pingüinos con el ala más larga, pesan más y tienen el pico más largo, pero bajo que los pingüinos con el ala más corta, menos pesados y con el pico más alto y corto.
- La correlación negativa entre la longitud de las alas y la altura del pico nos permite trazar la distinción entre dos grupos de pingüinos, hecho que podemos apreciar en el gráfico de dispersión entre ambas variables.



Ejemplo de baja correlación (negativa)



Ejemplo de alta correlación negativa



Ejemplo de alta correlación positiva

En estos primeros análisis solo podemos elucubrar sobre las posibles diferencias existentes entre las especies de pingüinos, aún así, es interesante ver cómo podemos comenzar a observar patrones al ordenar las muestras en base a sus distintas dimensiones. Concretamente, al organizar los datos enfrentandolos a bill_depth_mm, podemos ver agrupaciones claras de las nubes de puntos (posiblemente sea una variable clave).

2. *ANÁLISIS DE COMPONENTES PRINCIPALES (PCA): Selección de componentes principales.*

Habiendo estandarizado los datos, vamos a calcular el número de componentes principales óptimo con el que realizar nuestro análisis. Para ello primero vamos a llevar a cabo el análisis PCA con el número máximo de componentes (4, por ser 4 las variables continuas con las que trabajamos).

```
# Es importante apuntar que en ausencia de correlaciones nuestro ACP arrojaría
# resultados irrelevantes, ya que su funcionamiento depende de estas.

pca = PCA(n_components=4)   # Elegimos 4 máximo porque es el número de variables continuas del dataset original.

fit = pca.fit(datos_estandarizados)

autovalores = fit.explained_variance_

var_explicada = fit.explained_variance_ratio_*100

# Varianza explicada acumulada a medida que se agregan cada componente principal.
var_acumulada = np.cumsum(var_explicada)

# DataFrame de pandas con los datos anteriores e índice.
data = {'Autovalores': autovalores, 'Variabilidad Explicada': var_explicada, 'Variabilidad Acumulada': var_acumulada}
tabla = pd.DataFrame(data, index=['Componente {}'.format(i) for i in range(1, fit.n_components_+1)])

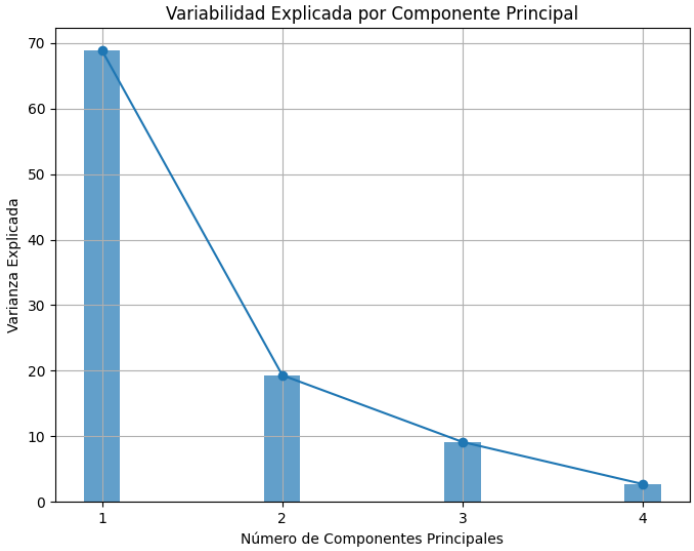
print(tabla)
```

	Autovalores	Variabilidad Explicada	Variabilidad Acumulada
Componente 1	2.761831	68.843878	68.843878
Componente 2	0.774782	19.312919	88.156797
Componente 3	0.366307	9.130898	97.287695
Componente 4	0.108810	2.712305	100.000000

Aquí disponemos de los autovalores, que son medida de la variabilidad de las variables explicada por cada componente. Se muestran ordenados, la primera componente es la que mayor variabilidad es capaz de explicar, mientras que la última es la que menor. La razón por la que escogemos solo los primeros componentes en un análisis de componentes principales es porque lo que buscamos es captar la mayor variabilidad posible de las variables originales reduciendo la dimensionalidad, al superponer la dirección de las variables originales sobre las componentes podremos ganar información sobre su funcionamiento conjunto, así como agrupaciones en base sus características.

Utilizaremos el *método del codo* para elegir el número de componentes principales que utilizaremos en el análisis. Para ello representamos la variabilidad explicada y vemos

a partir de qué componente la variabilidad explicada adicional proporciona un aporte de información innecesario.



A partir del primer componente podemos apreciar una caída repentina en los niveles de variabilidad explicada por las componentes, sin embargo, al elegir solo una componente, podemos estar cometiendo el error de que esta no sea capaz de explicar los efectos de las variables de forma completa. En otras palabras, el 19’31 de variabilidad explicada por el segundo componente podría estar captando efectos completamente inadvertidos por la primera componente. Por ello, tomar solo el primer componente podría suponer ser poco precavido de cara a disponer de información suficiente para el análisis; con este método concluimos que son necesarios 2 componentes principales.

3. *ANÁLISIS DE COMPONENTES PRINCIPALES (PCA): Análisis con 2 componentes principales.*

ANÁLISIS DE LAS COMPONENTES

Tras haber elegido las dos primeras componentes, volvemos a calcular los resultados del PCA y nos fijamos en la correlación entre componentes y variables:

```
Correlación entre componentes y variables:
                    Componente 1  Componente 2
bill_length_mm_z        0.755463      0.524748
bill_depth_mm_z        -0.664333      0.701180
flipper_length_mm_z     0.955862      0.002006
body_mass_g_z           0.909957      0.074149
```

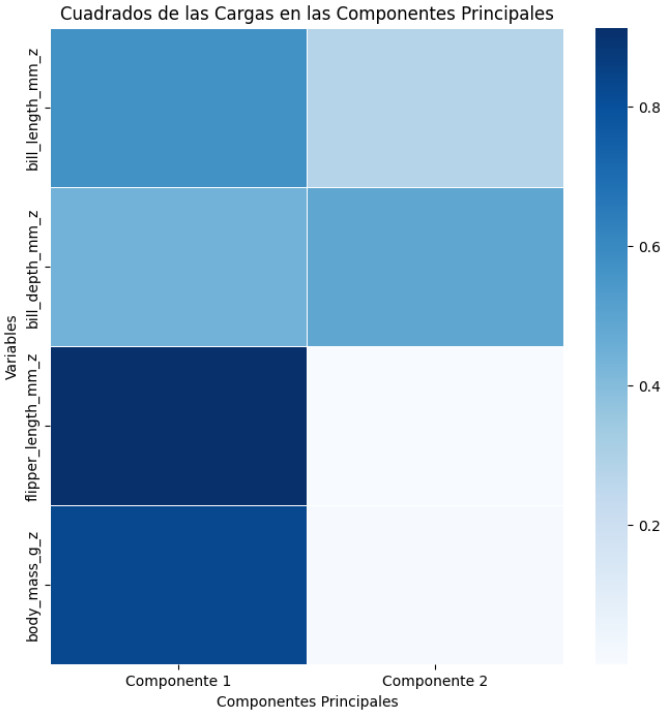
Gracias a esta medida, podemos ver cómo la primera componente es buena captando el efecto de la magnitud de las dimensiones del pingüino, puesto que está relacionada con el *peso* del animal, así como con la *longitud del pico* y de sus *alas*. Por otra parte, capta correlación negativa con la *profundidad del pico*. Del análisis que hacemos de la segunda componente podemos ver cómo la relación entre esta y la

profundidad del pico es positiva. De hecho, podríamos definir esta componente como las dimensiones o detalles del pico, pues poco tiene que ver con el *peso* o la *longitud del ala*.

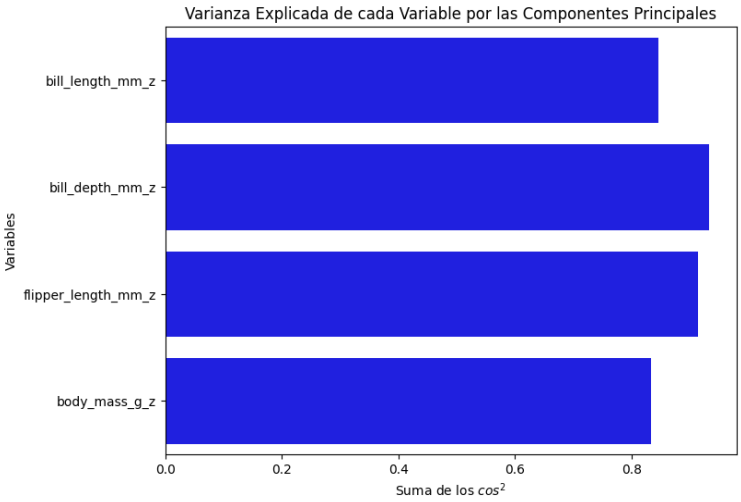
Podemos ver cuánto aporta cada componente al análisis de la variabilidad a través de los "Cosenos al cuadrado", una medida que nos dice el grado de variabilidad de las variables originales que es capaz de explicar cada componente (medida en porcentaje).

Cosenos al cuadrado

	Componente 1	Componente 2
bill_length_mm_z	0.570724	0.275361
bill_depth_mm_z	0.441338	0.491654
flipper_length_mm_z	0.913672	0.000004
body_mass_g_z	0.828021	0.005498

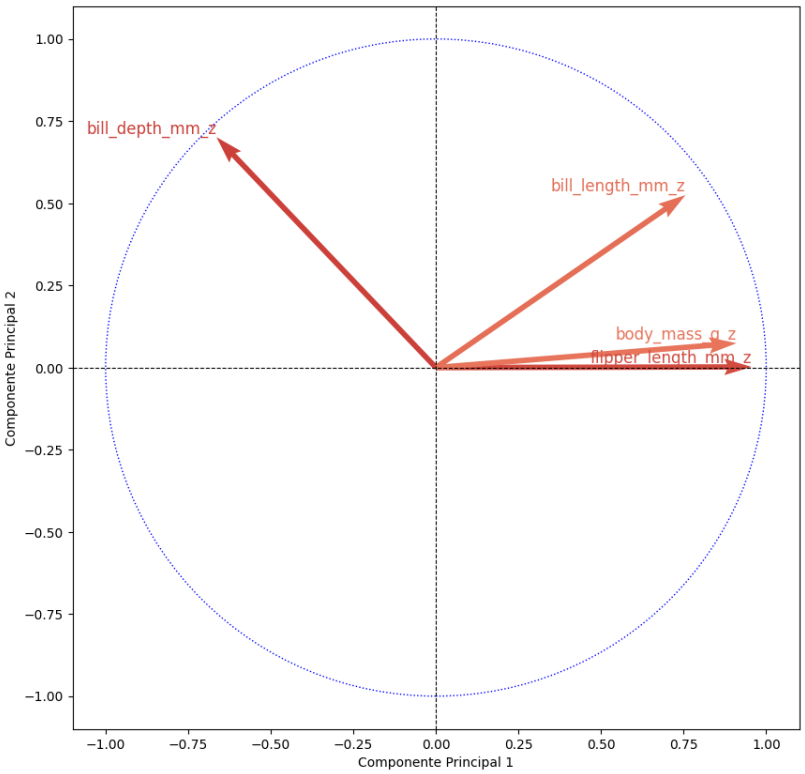


Aquí, podemos ver con mayor claridad cómo las variables captan las variables de las que hablamos. La primera componente capta mejor las dimensiones generales del pingüino mientras que la segunda componente es capaz de explicar mejor los matices del pico y, de hecho, es incapaz de captar las dimensiones generales del pingüino. La selección de 2 componentes parece acertada puesto que entre ambas componentes podemos explicar alrededor del 80% de la variabilidad de cada variable:



La suma de la explicabilidad de ambas componentes nos ofrece una variabilidad explicada más que aceptable para poder juzgar.

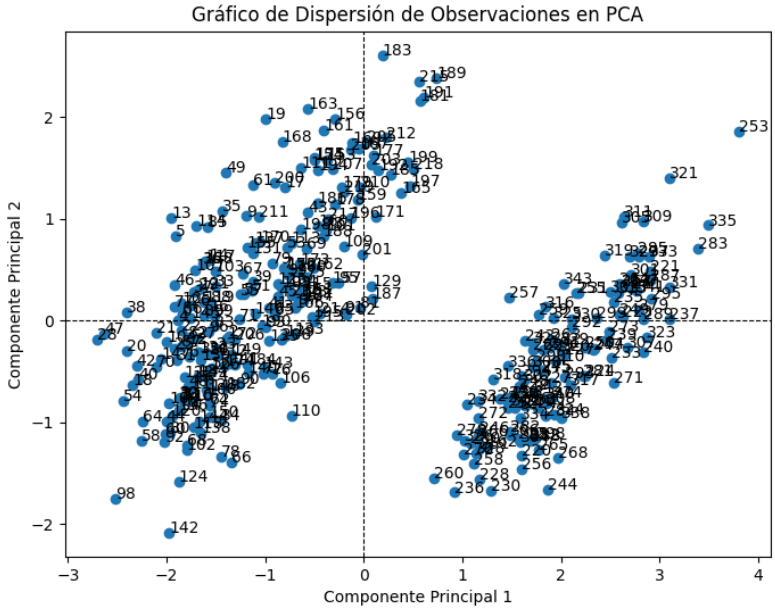
La conjunción entre la explicación sobre correlación y la de la explicabilidad de cada componente con respecto de las variables se puede resumir mediante el siguiente gráfico. En él se visualizan tanto las correlaciones (vectores), como la suma de los cosenos al cuadrado (color del vector) sobre los 2 ejes de nuestros componentes principales seleccionados.



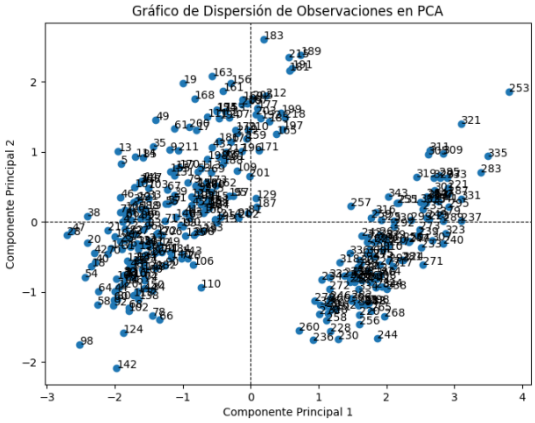
Tal y como comentábamos anteriormente, la profundidad y la longitud del pico son las variables menos correlacionadas con el primer componente y más captadas por el segundo.

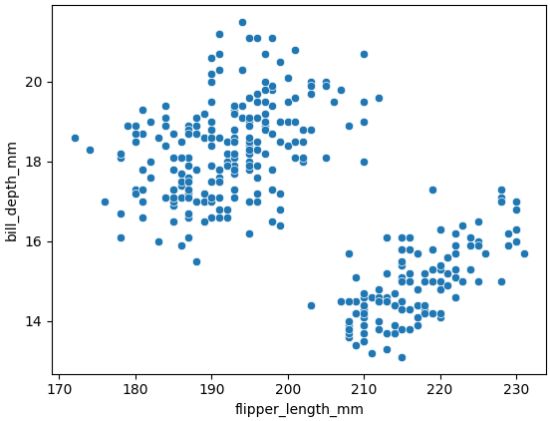
ANÁLISIS DE ESPECIES

Ahora vamos a estudiar la superposición de las muestras sobre el gráfico de PCA, generada a través de un gráfico de dispersión.



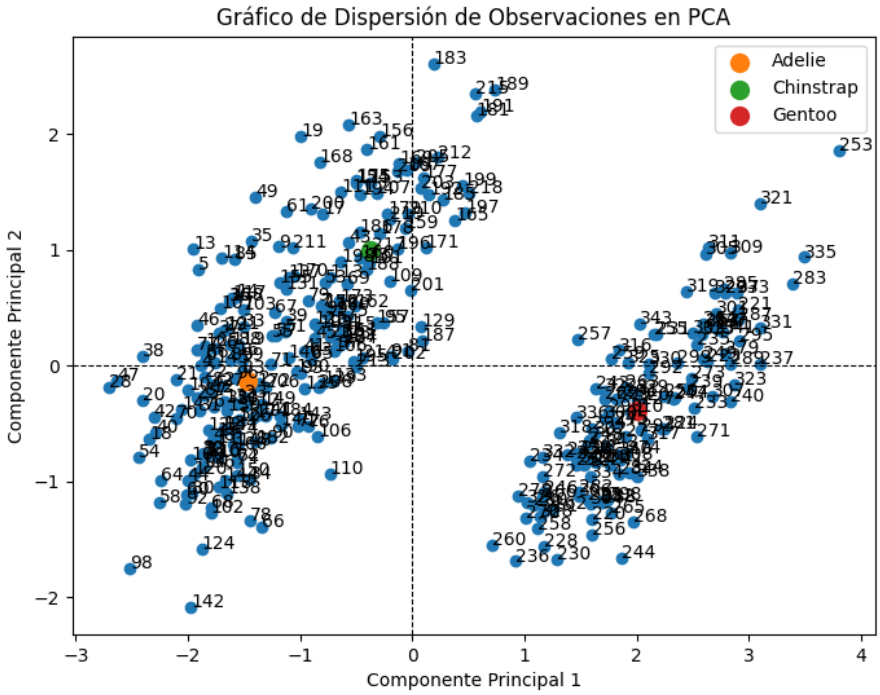
Se trata de un gráfico realmente interesante puesto que ya que nos puede recordar a los gráficos en los que anteriormente habíamos representado las muestras. De hecho, si nos retraemos al gráfico que compara la *longitud del ala* y la *profundidad del pico*, podremos observar un patrón muy similar:





No es casualidad que estas variables sean las que mayor coseno al cuadrado presenten para cada componente principal, y es que, son muy representativas de las componentes que hemos elegido para nuestro PCA, por eso también son las que mayor suma de cos2 muestran.

Al representar las especies de pingüinos (dibujando sus centroides) podemos ver claramente las tres agrupaciones y resumir sus características.



Los centroides nos dan una idea de cuál es la tendencia que muestran las características de la categoría que estudiemos. La especie con mayor envergadura es la Gentoo, que muestra una mayor concentración sobre los valores positivos de la primera componente principal. Mientras, las especies Chinstrap y Adelie son las que presentan

características más homogéneas entre sí. De ellas, Adelie es la especie más pequeña, dejando a la Chinstrap como “el pingüino mediano”. Entre estas dos últimas podemos trazar diferencias mucho más fundamentales en base a la dimensión de la segunda componente, como que la especie Chinstrap tiene un pico más desarrollado (es la especie con mayor longitud y profundidad del pico), mientras que la Gentoo tiene el pico más pequeño.

VALORACIÓN FÍSICA

Un índice que podemos aventurarnos a realizar es el de promediar la combinación lineal de las variables estandarizadas multiplicadas por el valor de los autovectores asociados a cada variable.

```
autovectores = pca1.components_.T
cp1_coef = autovectores[:, 0]  # Primera columna: coeficientes de PC1

indice = datos_estandarizados.values @ cp1_coef


datos_indice = df_sup.copy()  # Datos estandarizados
datos_indice["indice"] = indice

# Valor promedio del índice por especie
indice_especie = datos_indice.groupby("species")["indice"].mean()
print(indice_especie)
```

Agrupando los resultados por especie obtenemos:

```
species
Adelie      -1.463897
Chinstrap   -0.377341
Gentoo       2.005753
```

El resultado está alineado con el análisis realizado en el apartado anterior, Gentoo es la especie con un físico general más desarrollado mientras que Adelie es la especie más pequeñas, por lo que el índice funciona. Si hubiésemos querido hacer un índice sobre las cualidades del pico hubiésemos hecho lo propio con la componente 2. Al basarse en los valores de las coordenadas del PCA, el índice presenta valores positivos y negativos, pero sin un valor de referencia claro. Por eso deben interpretarse de forma conjunta, relativizando unos a otros (no hay una referencia de la puntuación que deba arrojar el índice).

Ahora que ya hemos recabado información sobre las variables mediante nuestro análisis exploratorio PCA, podemos adentrarnos en llevar a cabo agrupaciones.

4. *AGRUPAMIENTO JERÁRQUICO.*

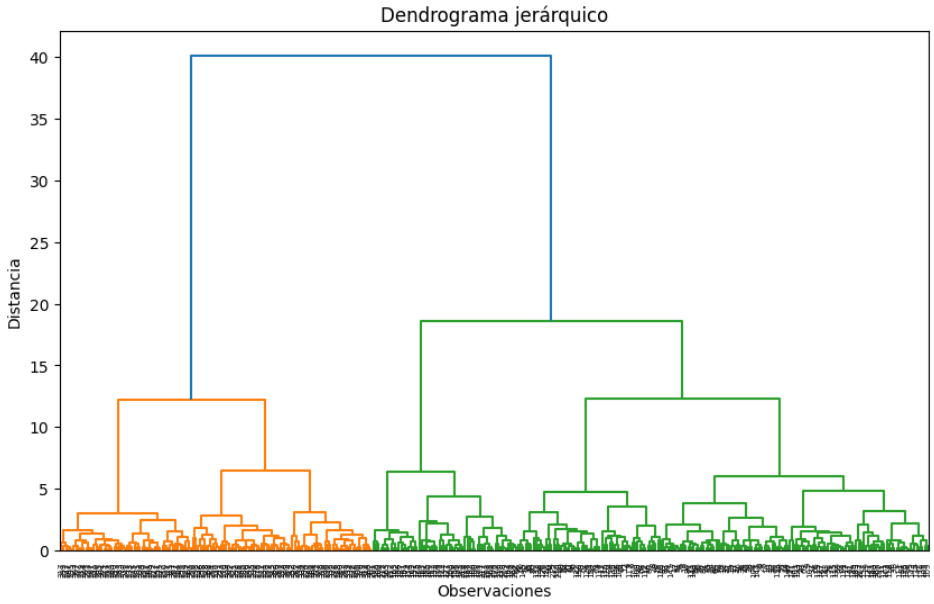
Vamos a comenzar a estudiar la agrupación de nuestras muestras en base al agrupamiento jerárquico. Esta metodología está basada en la agrupación a través de distancias, primero entre observaciones y, después, entre variables.
El primer paso es estandarizar las variables, después calculamos las distancias entre ellas y finalmente construimos el árbol jerárquico mediante la *distancia de Ward* (minimiza la varianza entre las observaciones de cada grupo).

```
# Estandarizamos los datos
df_std = pd.DataFrame(StandardScaler().fit_transform(df_cont), columns=df_cont.columns)

# Calculo de la matriz de distancias
dist_condensada = pdist(df_std, metric='euclidean')

# Creación del árbol jerárquico
linkage_matrix = sch.linkage(dist_condensada, method='ward')
```

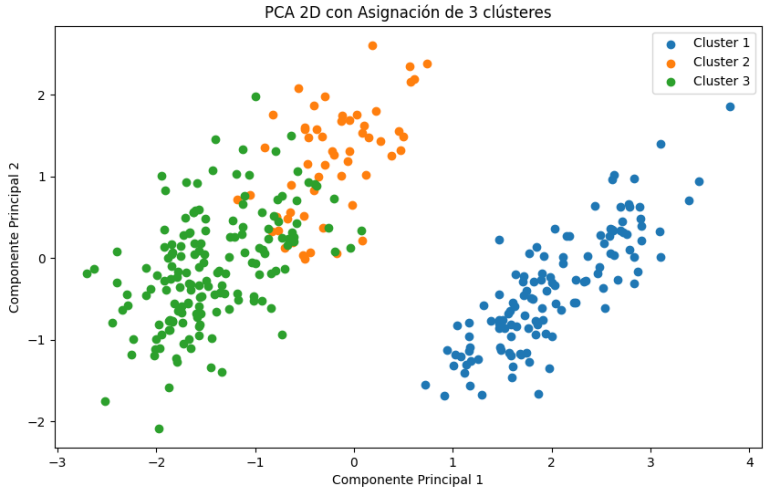
Podemos visualizarla a través de su dendograma:



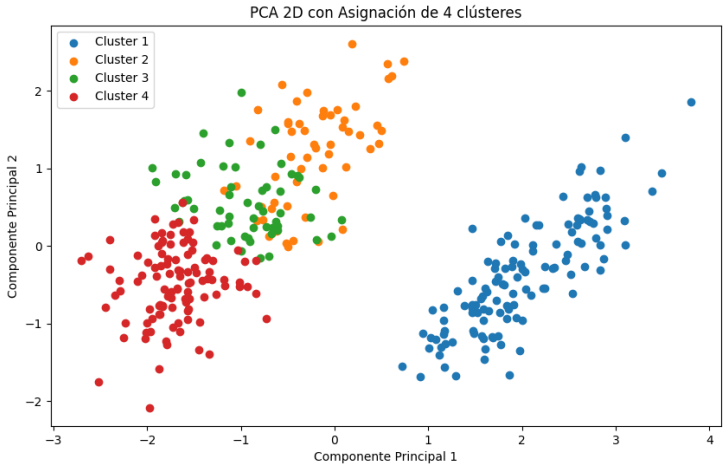
En él ya podemos ver algunos patrones repetidos, como la selección de hasta 3 grandes grupos (dos de ellos muy relacionados) que podrían corresponderse con las especies (la ramificación de color naranja pertenecería a la especia Gentoo, que presenta características distintas a las otras dos). Podemos también aventurarnos a establecer que el grupo de la derecha es la especia Adelie (el más amplio y alejado de Gentoo). Podríamos cortar en k=15 y tener 3 clústeres, o cortar en k=10 y tener 5 clústeres. Para todos los clústeres jerárquicos la elección de una distancia k está sometida al juicio personal, aquí, la elección de k=15 nos daría a los tres grupos de los que hablamos. Nos interesará elegir una distancia menor cuando queramos observar relaciones más específicas, detalles mucho más desagregados. De desagregar demasiado, pordríamos cometer el error de perder las agrupaciones de vista y, de escoger agrupaciones muy generales, no podríamos distinguir correctamente entre los grupos.

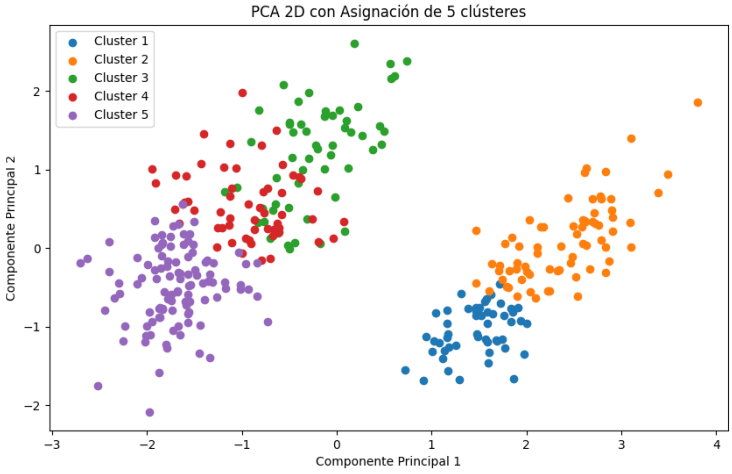
Ya que la elección de los tres grupos no sucede a una altura muy alta, seleccionaremos un corte de k=15, 3 grupos.

Al graficar cada grupo dentro del PCA el resultado es muy similar al obtenido al superponer los centroides de la variable *especie* sobre el análisis PCA:



Conforme aumentamos la distancia elegida en el dendograma, vamos distinguiendo nuevas agrupaciones, podemos ver que con el método de selección jerárquica con distancia de Ward primero realiza distinciones entre los grupos más parecidos (Adelie y Chinstrap) y posteriormente detecta diferencias intragrupo para la especie Gentoo.

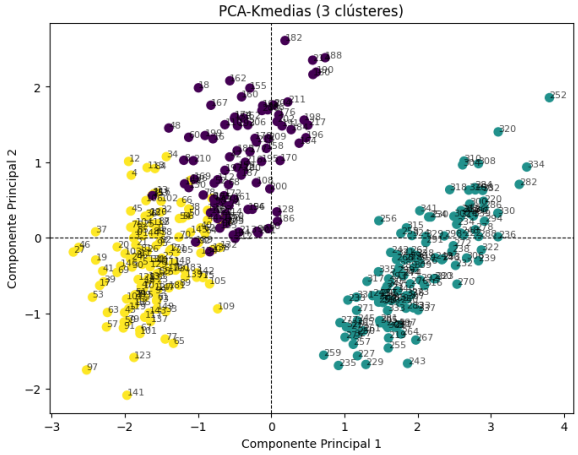




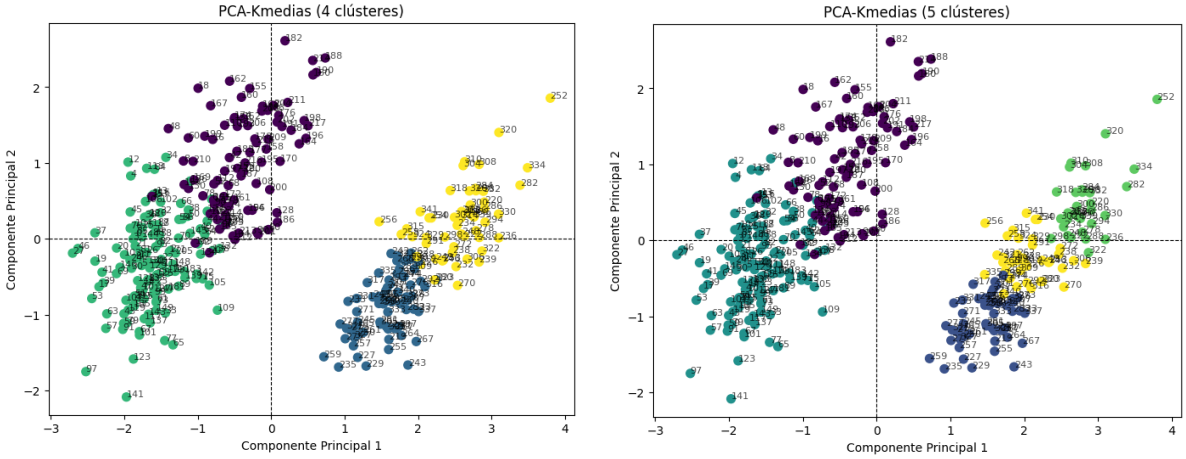
Continuamos estudiando nuestro conjunto de datos mediante el análisis de k-medias.

5. AGRUPAMIENTO K-MEDIAS.

El análisis de k-medias se diferencia del método jerárquico en que el número de grupos es escogido previamente, agrupando las observaciones dada la distancia a los centroides creados. Así, si elegimos que queremos 3 grupos, el método consiste en calcular 3 centroides y asignar a cada observación su centroide más cercano. Como hemos visto, existen diferencias fisiológicas entre especies, por lo que parece razonable partir de 3 agrupaciones:

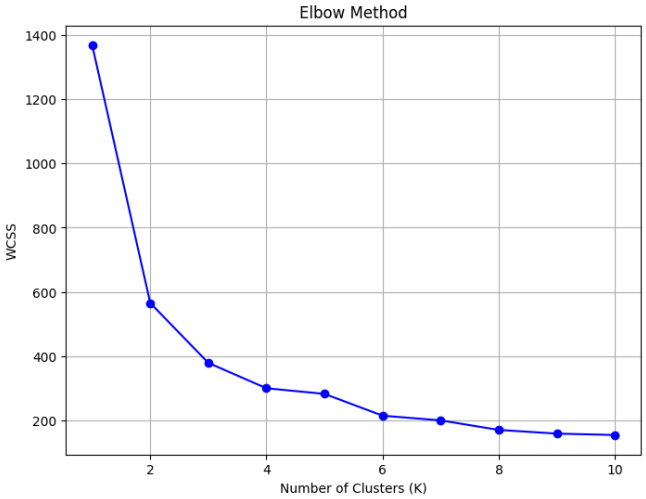


El resultado para la agrupación de 3 es similar a las encontradas anteriormente, consigue distinguir entre especies de pingüino.



Conforme aumentamos el número de agrupaciones vemos que este método crea clústeres similares pero las distinciones que genera van al grupo Gentoo. Cabe a destacar cómo a pesar de ser muchas más las observaciones entre Adelie y Chinstrap la agrupación de 5 k-medias lleva a cabo hasta 3 agrupaciones en el centroide de Gentoo. Esto se debe a que el método de k-medias propone centroides que minimizan la variabilidad dentro de este. Como Gentoo muestra una variabilidad intraespecie mayor a la de Adelie, o Chinstrap, los primeros clústeres tratan de identificar y agrupar las diferencias dentro de este grupo (de nuevo, por su mayor variabilidad).

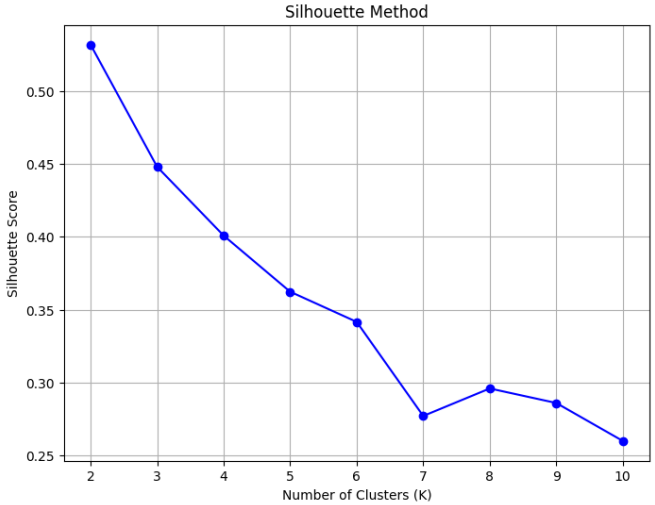
Al tratarse nuevamente de un análisis exploratorio, la selección de un número k de agrupaciones es parte de un proceso arbitrario. Para ayudarnos a elegir un número óptimo para nuestro análisis, vamos a recurrir al método del codo, por el cuál observamos cómo la suma de cuadrados intragrupal disminuye conforme aumentamos el número de grupos. De esa forma, podemos ver visualmente cuando, al añadir un grupo más, la variabilidad intragrupal deja de disminuir rápidamente; será entonces cuando no nos convenga desagregar más las observaciones.



El método del codo parece estar indicándonos que 4 agrupaciones es un número de agrupaciones correcto. Así, aceptaríamos las agrupaciones por especie más la desagregación en dos grupos de la especie Gentoo (grupos que podrían estar indeterminados más allá de la variabilidad de sus características físicas).

6. VALIDACIÓN DEL AGRUPAMIENTO.

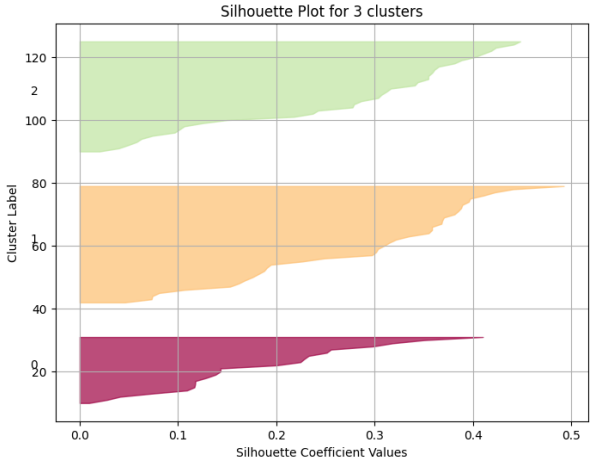
Para validar la cantidad de agrupamientos vamos a utilizar el método de la silueta, que asigna una puntuación a las agrupaciones en base a si las observaciones están cerca de sus clústeres y cómo de cerca se encuentra de otros clústeres. En otras palabras, es un índice que nos indica si la estructura geométrica de los datos se adecúa más a cierto número de agrupaciones (siempre independientemente de sus valores categóricos).

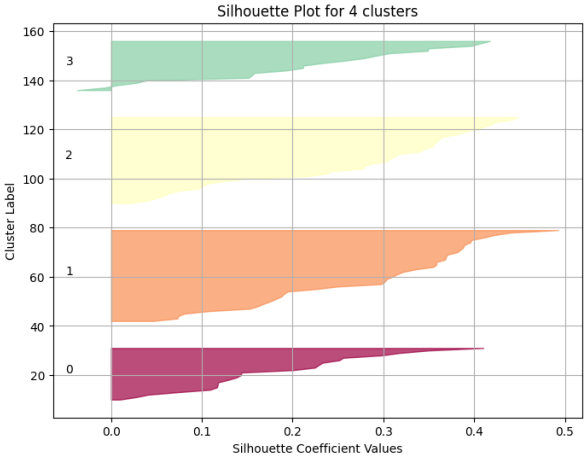


En este caso, el método de la silueta nos indica que la agrupación más correcta es crear dos grupos, pues es el número de agrupaciones con mayor puntuación. Cabe discutir que dos sea el número correcto de agrupaciones, pues el resultado es simplista a menos de que en nuestro análisis el resultado que estemos buscando sea la visualización de similitudes en base a distintas características. De base nuestro análisis se ha estado enfocando en la distinción las tres especies de pingüinos, sin embargo, este método ha evidenciado una de las perspectivas que arrojábamos al estudiar el posicionamiento de los centroides de especie en el PCA: la especie Adelie y la especie Chinstrap no presentan características tan distintas.

Por otra parte, escoger tres, o hasta cuatro clústeres, no tiene por qué ser algo malo. Se trata de una cuestión de interpretación de los resultados de este método de puntuación, sabiendo que una puntuación de ~0'4 significa que los grupos se solapan, todo está correcto. Un hallazgo también interesante es ver cuánto caen los sucesivos grupos en esta puntuación, lo que sirve como aviso sobre el solape entre centroides y la posible creación de grupos que no tengan un significado intrínseco (crear 10 o más grupos para un conjunto de datos con 4 variables discretas seguramente no tenga sentido).

Al plasmar las puntuaciones de silueta de cada observación, en agrupación a su clúster, podemos ver más fácilmente si surgen problemas al crear nuevos grupos.





Como podemos ver, el paso de 3 a 4 agrupaciones complica el análisis en cuanto a que surgen puntuaciones de silueta negativas que evidencian el solapamiento entre grupos. Podemos ver en la forma de las puntuaciones de silueta que las etiquetas ofrecidas al método son las formadas anteriormente por el método de elección de k-medias. También podemos apreciar que muchas de las observaciones muestran puntuación de silueta baja, resultado de presentar características menos definidas con respecto al punto centroide que tienen por referencia.

7. *MÉTODO JERÁRQUICO VS K-MEDIAS. Comparativa entre análisis.*

Debido a la distinta forma en la que funcionan ambos métodos, lo más complicado es conseguir resultados comunes donde, tal vez, si podamos encontrar tranquilidad en el análisis. Por otra parte, habiéndolos interpretado correctamente, tampoco debemos temer a las diferencias que presentan.

Continuando con nuestro análisis de especies (usando 3 agrupaciones para tratar de conocer el funcionamiento de los modelos), podemos ver como el método de agrupación jerárquica sobreestima el número de pingüinos de la especie Adelie, mientras que la agrupación de k-medias lo subestima.

Gentoo: grupo con 123 observaciones.
Adelie: grupo con más obvs.
Chinstrap: grupo con menos obvs.

```
K-medias:
 Frecuencia de datos en cada agrupación:
 {0: 86, 1: 123, 2: 133}

Agrupación jerárquica:
 Frecuencia de datos en cada agrupación:
 {1: 123, 2: 57, 3: 162}
```

Como hemos visto en los gráficos anteriores, el método jerárquico es más permisivo a la hora de generar una frontera entre grupos. El método de k-medias, estando basado en la distancia respecto a un centroide, crea fronteras más sólidas. El método de k-medias es más sensible a la estructura geométrica de los datos mientras que el método jerárquico puede captar mejor la estructura interna de las observaciones, observando las distancias entre las distintas variables que presentan.

Ambos han acertado al captar el patrón de los pingüinos Gentoo, sin embargo, el método k-medias no ha conseguido distinguir correctamente el solape entre las observaciones de los pingüinos Chinstrap y Adelie, al que se ha acercado de forma más correcta el método jerárquico.

Otra de las diferencias fundamentales entre la aplicación de ambos métodos ha sido la forma en que actúan al aumentar el número de grupos elegidos. Mediante el método jerárquico, se puede ver como realiza primero una diferenciación entre las características del "grupo de solape" entre Adelie y Chinstrap, para continuar con la diferenciación intragrupal de Gentoo. La forma en la que ha actuado el método de k-medias ha sido desagrupando el grupo Gentoo en hasta 3 grupos antes de pasar al solape entre las otras especies. Esto se debe a, tal y como se ha explicado anteriormente, la mayor variabilidad intraespecie que presenta este grupo de pingüinos con respecto a los otros.

Lo cierto es que ninguno de los métodos de agrupamiento ha arrojado un mal resultado, pero hemos aprendido que el método jerárquico funciona mejor que el método de k-medias cuando varios de los grupos a estudiar presentan características comunes.

8. INTERPRETACIÓN DE LOS GRUPOS.

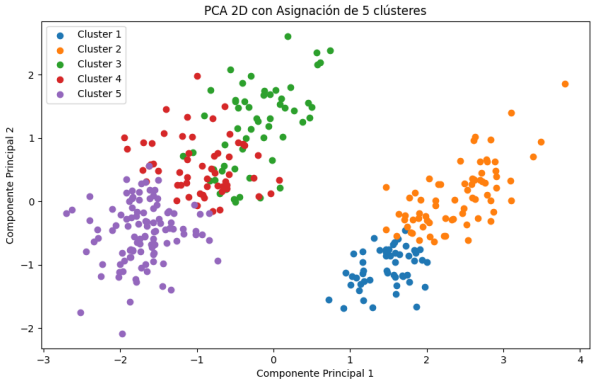
A lo largo de todo el estudio hemos discutido las diferentes características que presentan los pingüinos, así como la significatividad de estas. El análisis de componentes principales nos ha permitido ver una de las características más esenciales para poder clasificar las observaciones: existen diferencias significativas basadas en el volumen físico de los animales. No solo eso, sino que, al superponer los centroides de la etiqueta de especie sobre el análisis PCA, hemos visto que las agrupaciones entre especie presentan rasgos físicos verdaderamente distintivos. Hemos visto que existen dos componentes principales: el tamaño general del animal, y los matices del pico (siendo la profundidad de este una característica fundamental).

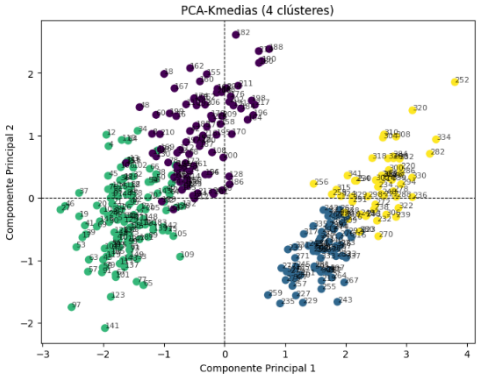
Este análisis podíamos intuirlo al mostrar los gráficos de dispersión entre pares de variables, la longitud del ala y la profundidad del pico son rasgos muy distintivos entre estos pingüinos. Sin embargo, no ha sido hasta que hemos realizado el análisis de variabilidad explicada por los componentes del PCA hasta que lo hemos podido confirmar.

Tanto el método de agrupación jerárquico como el método de k-medias han avalado la hipótesis de la diferenciación física entre especies. En el proceso hemos aprendido que el método de agrupación jerárquico funciona mejor a la hora de detectar patrones inherentes a la estructura de las observaciones mientras que k-medios trabaja mejor en estructuras bien delimitadas.

Hemos verificado que la agrupación más correcta para nuestros datos consiste en la creación de 3 grupos (coincidentes con estas especies).

Una última cuestión que nos quedaría por abordar es si, al aumentar el tamaño de los grupos hubiésemos encontrado información algo más esclarecedora de las características de estos animales. Si bien es cierto que resultaría interesante profundizar en el análisis de la frontera entre las especies Adelie y Chinstrap, lo que quiero comprobar a continuación es el funcionamiento de la estructura interna para los datos de los pingüinos Gentoo. Cuando aumentamos el número de agrupaciones a 5 en el análisis jerárquico y a 4 en el de k-medias, se realiza una distinción entre dos subgrupos de esta especie.





Con un poco de lógica averiguamos que se tratan de diferencias entre género, pues, como debemos recordar, la única ubicación en la que fueron registrados estos pingüinos fue en la isla de Biscoe. Lo que toca ahora es averiguar qué género presenta qué características.

Al agrupar el dataset por especie Gentoo y los distintos géneros, podemos crear tablas de descriptivos específicas a ellos:

Gentoo masculino:

	count	mean	std	min	25%	50%	75%	max	Varianza	Coeficiente de Variación
bill_length_mm	65.0	49.236923	2.810058	44.4	47.3	49.4	50.5	59.6	29.807054	0.124302
bill_depth_mm	65.0	15.646154	0.790980	13.8	15.1	15.7	16.1	17.3	3.899808	0.115140
flipper_length_mm	65.0	221.184615	5.675860	208.0	216.0	221.0	225.0	231.0	197.731792	0.069988
body_mass_g	65.0	5429.615385	380.169892	4100.0	5250.0	5500.0	5700.0	6300.0	643131.077327	0.190862

Gentoo femenino:

	count	mean	std	min	25%	50%	75%	max	Varianza	Coeficiente de Variación
bill_length_mm	58.0	45.563793	2.051247	40.9	43.85	45.50	46.875	50.5	4.207613	0.046702
bill_depth_mm	58.0	14.237931	0.540249	13.1	13.80	14.25	14.600	15.5	0.291869	0.031499
flipper_length_mm	58.0	212.706897	3.897856	203.0	210.00	212.00	215.000	222.0	15.193285	0.019401
body_mass_g	58.0	4679.741379	281.578294	3950.0	4462.50	4700.00	4875.000	5200.0	79286.335451	0.067014

Como podemos observar, los varones Gentoo presentan unas características físicas, en media superiores, aunque con índices de variación algo mayores a los de los Gentoo hembra. Por lo que, con los datos que manejamos, el género sería la característica a través de la cuál definiríamos a ambos grupos (Gentoo masculino es el grupo ubicado más en positivo para ambos componentes puesto que, en media, presenta características físicas más grandes).

9. RESUMEN DE HALLAZGOS Y CONCLUSIÓN.

Verdaderamente los hallazgos encontrados ya han sido resumidos en el apartado *(8)*, por lo que me remitiré a concluir que la dificultad en este tipo de análisis se encuentra en saber valorar en todo momento los datos que se presentan enfrente e ir tejiendo estos con los hallazgos previos para crear una narrativa que sea tan convincente y contrastable mediante una metodología firme. Como en todo análisis exploratorio de datos, se trata muchas veces de conocer bien las técnicas y atacar los datos de todas las formas posibles a fin de recabar cuanta más información y perspectivas. Ello incluye saber desarrollar un criterio para, como se ha comentado en el análisis, poder tomar decisiones subjetivas (como decidir sobre el número de agrupaciones con las que trabajar).